

Coercivité, méthode du gradient

Epreuve X-ENS 2012 PSI.

Préambule

1. On écrit la définition de la limite infinie en posant $A = |f(0)| + 1$. Il existe $M > 0$ tel que pour tout $x \in \mathbb{R}^n$, $\|x\| > M \Rightarrow f(x) \geq |f(0)| + 1$.

2. Soit K la boule fermée de \mathbb{R}^n de centre 0 et de rayon M . Il s'agit d'une partie fermée de \mathbb{R}^n qui est de dimension finie. C'est donc un fermé borné, et f est continue sur cette partie, donc admet une borne inférieure, atteinte en au moins un point. On note x^* un tel point.

On a déjà pour tout $x \in K$, $f(x^*) \leq f(x)$. Notamment $f(x^*) \leq f(0) < |f(0)| + 1$.

Alors, pour tout $x \notin K$, on a $\|x\| > M$ et par suite $f(x) \geq |f(0)| + 1 > f(x^*)$. La propriété $f(x^*) \leq f(x)$ est prouvée pour tout x .

Une fonction coercive de \mathbb{R}^n dans \mathbb{R} présente un minimum global.

3. Comme f est une fonction de classe \mathcal{C}^1 sur \mathbb{R}^n qui est un ouvert, tout extremum (même local) de f est un point critique : $\nabla f(x^*) = 0$.

J'ai considéré - ça se discute - qu'on ne demandait pas de preuve mais l'énoncé précis du théorème, avec le mot "ouvert". Sinon on peut dire : chaque $h \mapsto f(x_1^, \dots, x_i^* + h, \dots, x_n^*)$ admet un extremum en $h = 0$, donc une dérivée nulle : $\frac{\partial f}{\partial x_i}(x^*) = 0$.*

Partie 1

4. On utilise Cauchy-Schwarz pour encadrer le terme (b, x) : $|(b, x)| \leq \|b\| \cdot \|x\|$.

Par suite, $g(x) \geq \frac{1}{2}C\|x\|^2 - \|b\| \cdot \|x\| = \|x\|(C\|x\| - \|b\|)$.

Pour $\|x\| > \frac{2\|b\|}{C}$, on voit que $\|g(x)\| \geq \|x\| \cdot \|b\|$, et cela tend vers l'infini lorsque $\|x\|$ tend vers l'infini.

La fonction g est coercive.

5. On peut tout exprimer en coordonnées et dériver par rapport à chaque variable (il y aurait un calcul plus adapté par DL global, mais c'est moins l'optique du programme actuel). En regroupant les termes identiques par symétrie de A ,

$$g(x_1, x_2, x_3) = \frac{1}{2}(a_{11}x_1^2 + a_{22}x_2^2 + a_{33}x_3^2) + a_{12}x_1x_2 + a_{13}x_1x_3 + a_{23}x_2x_3 - b_1x_1 - b_2x_2 - b_3x_3$$

Par sommes et produits de fonctions coordonnées, g est une fonction \mathcal{C}^1 sur \mathbb{R}^3 , avec

$$\nabla g(x_1, x_2, x_3) = \begin{pmatrix} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 - b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 - b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 - b_3 \end{pmatrix}$$

On reconnaît ce vecteur gradient : c'est $\nabla g(x) = Ax - b$.

Comme g est coercive, le préliminaire montre qu'elle possède un minimum global x^* . De plus, en un tel minimum, le gradient de g s'annule. Le ou les points où g atteint son minimum sont à chercher parmi les solutions de l'équation $Az = b$.

Or la relation $Az = b$ est un système linéaire. Examinons les propriétés de la matrice A . Si x est un vecteur de $\ker A$, $(Ax, x) = 0$ et par suite $C\|x\|^2 \leq 0$. Puisque $C > 0$ cela montre que $x = 0$. Ainsi A est injective.

Le système $Az = b$ admet une unique solution $x^* = A^{-1}b$, unique extremum local de g , qui est en fait minimum global.

6. Calculons comme indiqué

$$u_{k+1} - x^* = u_k - \alpha Au_k + \alpha b - x^* = (u_k - x^*) - \alpha A(u_k - x^*) = (I_3 - \alpha A)(u_k - x^*).$$

7. Une récurrence évidente permet d'établir que $u_k - x^* = (I_3 - \alpha A)^k(u_0 - x^*)$.

On sait que comme A est symétrique réelle, elle est diagonalisable dans une base orthonormale $B = (e_1, \dots, e_2, e_3)$. On note P la matrice de passage de la base canonique à la base B . Soient $\lambda_1, \lambda_2, \lambda_3$ les valeurs propres de A . Observons d'abord que l'hypothèse faite sur A donne une contrainte sur ces valeurs propres : $(Ae_i, e_i) = \lambda_i(e_i, e_i) = \lambda_i \geq C > 0$. Par ailleurs,

$$I - \alpha A = I - \alpha P D P^{-1} = P D' P^{-1}, \quad \text{où } D = \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \lambda_3 \end{pmatrix}, \quad D' = \begin{pmatrix} 1 - \alpha \lambda_1 & & \\ & 1 - \alpha \lambda_2 & \\ & & 1 - \alpha \lambda_3 \end{pmatrix}.$$

Pour chaque i , on a $0 < \alpha \lambda_i \leq \alpha L < 2$. Ainsi $-1 < 1 - \alpha \lambda_i < 1$.

La matrice D a tous ses coefficients diagonaux dans $] -1, 1[$. On peut affirmer que les puissances $(D')^k$ ont une limite nulle et par suite $(I - \alpha A)^k$ tend vers 0.

On trouve enfin que la suite (u_k) converge vers x^* .

Partie 2

8. On envisage les trois cas

- si $x_k = 0$, alors $x_{k+1} = 0$ et ainsi $h(x_k) = h(x_{k+1})$.
- si $x_k > 0$, alors $x_{k+1} = x_k - t_k$ et ainsi $-x_k < x_{k+1} < x_k$. On en tire $0 < |x_{k+1}| < |x_k|$, puis par croissance de $h : x \mapsto x^2$ sur \mathbb{R}_+ , $h(x_{k+1}) < h(x_k)$.
- si $x_k < 0$, alors $x_{k+1} = x_k + t_k$ et ainsi $x_k < x_{k+1} < -x_k$. On en tire $0 < |x_{k+1}| < |x_k|$, et de nouveau $h(x_{k+1}) < h(x_k)$.

Dans tous les cas, $\forall k \in \mathbb{N}, h(x_{k+1}) \leq h(x_k)$.

9. On peut calculer le terme général de cette suite

$$v_k = \sum_{p=1}^k (v_p - v_{p-1}) + v_0 = 2 - \sum_{p=1}^k \frac{1}{2^p} = 2 - \left(1 - \frac{1}{2^k}\right) = 1 + \frac{1}{2^k}$$

Les termes de la suite sont tous positifs. On pose donc pour tout k , $\varepsilon_k = -1$ et $t_k = \frac{1}{2^{k+1}} \leq \frac{1}{2} < 2|v_k|$. On a bien $v_{k+1} = v_k + t_k \varepsilon_k$ avec les conditions désirées sur t_k et ε_k . La suite forme bien une descente par gradient pour h . Cependant sa limite est 1 qui n'est pas un point où h atteint son minimum global.

On a trouvé un exemple de descente par gradient qui converge vers un point autre que le minimum global.

10. De nouveau le calcul complet est possible, et utile pour trouver le signe de w_k .

$$w_k = \sum_{p=1}^k (w_p - w_{p-1}) + w_0 = 2 + 2 \sum_{p=1}^k (-1)^p + 3 \sum_{p=1}^k \left(\frac{-1}{2}\right)^p = 2 \sum_{p=1}^k (-1)^p + 1 + \frac{(-1)^k}{2^k} = \begin{cases} 1 + \frac{1}{2^k} & \text{si } k \text{ est pair} \\ -1 - \frac{1}{2^k} & \text{si } k \text{ est impair} \end{cases}$$

La sous-suite des termes d'indices pairs (w_{2k}) converge vers 1, celle des termes d'indice impair vers -1 . Donc la suite (w_k) diverge.

On pose cette fois $t_k = 2 + \frac{3}{2^{k+1}} < 2\left(1 + \frac{1}{2^k}\right)$ et $\varepsilon_k = (-1)^{k+1}$ qui est de signe opposé à x_k . On a bien les hypothèses pour affirmer que (w_k) forme une descente par gradient.

On a trouvé un exemple de descente par gradient qui ne converge pas.

Partie 3

11. Si le vecteur $u = \nabla f(x)$ est non nul, on pose $d = -\frac{u}{\|u\|}$ et on a bien les relations $\|d\| = 1$ et $(d, \nabla f(x)) = -\frac{\|u\|^2}{\|u\|} < 0$.

Si x n'est pas un point critique, D_x est non vide (et réciproquement!).

Prenons $d \in D_x$ et formons le DL de $f(x + td)$: on étudie la fonction le long d'une droite d'origine x et dirigée par d (expression $\phi(t) = f(\gamma(t))$ avec $\gamma(t) = x + td$). Comme f est \mathcal{C}^1 ,

$$\phi'(t) = \frac{d}{dt}f(x + td) = \frac{d}{dt}f(\gamma(t)) = (\gamma'(t)|\nabla f(\gamma(t))) = (d, \nabla f(x + td))$$

Rappel : si on n'est pas à l'aise avec cette formule, on peut le considérer comme $f(x_1 + td_1, x_n + td_n)$.

Notamment en $t = 0$, cette dérivée vaut $\phi'(0) = (d, \nabla f(x))$, et on note cette valeur α , avec $\alpha < 0$ par définition de d .

$$f(x + td) = f(x) + t(d, \nabla f(x)) + o(t) = f(x) + \alpha t + o(t).$$

Reprenons la définition de $o(t)$: il existe $\eta > 0$ tel que si $t \in]0, \eta[$, alors le terme en $o(t)$ est majoré par $\frac{1}{2}|\alpha|t = -\frac{1}{2}\alpha t$. Ainsi pour $t \in]0, \eta[$, $f(x + td) - f(x) < \alpha t - \frac{1}{2}\alpha t < 0$.

L'intervalle $]0, \eta[$ appartient à $T_{d,x}$.

Pour tout $d \in D_x$, $T_{d,x}$ est non vide. Précisément, il existe $\eta_d > 0$ tel que $]0, \eta_d[\subset T_{d,x}$.

NB : il est important de réaliser que c'est pour chaque d qu'on trouve un η_d (raisonnement uniquement le long d'une direction); rien ne dit qu'il existe un η valable pour tous les $d \in D$.

12. Attention quand on dit "coïncide" ça va dans les deux sens : dans le cas de la fonction h on a deux définitions (celle de la partie 2 et celle de la partie 3); il faut montrer que (x_k) vérifie l'une si et seulement si elle vérifie l'autre.

Commençons par poser un peu le cadre : ici $n = 1$, $\mathbb{R}^n = \mathbb{R}$, le produit scalaire est le produit ordinaire, le gradient de h est $h'(x) = 2x$, les seuls vecteurs de norme 1 sont 1 et -1.

Le cas $x_k = 0$ donne lieu à la même convention pour les deux définitions : $x_{k+1} = x_k$. Supposons maintenant $x_k \neq 0$.

La relation $x_k > 0$ revient au même que $(\nabla h(x_k)|1) > 0$, donc $\varepsilon_k = -1$ revient au même que $d_k = -1$. De même $\varepsilon_k = 1$ revient au même que $d_k = 1$.

Comparons maintenant ε_k et t_k . Les scalaires t_k sont choisis dans \mathbb{R}_+^* pour respecter la condition

$$(x_k + t_k \varepsilon_k)^2 < x_k^2 \Leftrightarrow 2t_k x_k \varepsilon_k + t_k^2 < 0 \Leftrightarrow t_k(2x_k \varepsilon_k + t_k) < 0 \Leftrightarrow t_k < -2x_k \varepsilon_k = 2|x_k|,$$

puisque x_k et ε_k sont de signe opposé. On a prouvé, pour des $t_k > 0$, l'équivalence des conditions $t_k \in]0, 2|x_k|[$ et $t_k \in T_{x_k, d_k}$.

Les deux définitions de la descente par gradient proposées pour la fonction h coïncident.

13. La suite des valeurs $f_k = f(x_k)$ est décroissante puisqu'on a soit $x_{k+1} = x_k$, soit $f(x_{k+1}) < f(x_k)$. En outre (f_k) est minoré par le minimum global $f(x^*)$ dont on a prouvé l'existence en préambule. La suite (f_k) , décroissante et minorée, est donc convergente.

La suite (f_k) est donc bornée par une constante $K > 0$. En reprenant l'argument de la question 1, il existe une valeur $N > 0$ telle que $\|x\| > N \Rightarrow f(x) > K$. Ainsi les vecteurs x_k vérifient tous $\|x_k\| \leq N$.

La suite (x_k) est bornée; la suite $(f(x_k))$ est convergente.

14. Calculons comme demandé, en faisant systématiquement apparaître r_k : $u_{k+1} = u_k - \alpha r_k$ et $Au_k = r_k + b$:

$$\begin{aligned} g(u_{k+1}) - g(u_k) &= \frac{1}{2}(A(u_k - \alpha r_k), u_k - \alpha r_k) - (b, u_k - \alpha r_k) - \frac{1}{2}(Au_k, u_k) + (b, u_k) \\ &= -\alpha(Au_k, r_k) + \frac{1}{2}\alpha^2(Ar_k, r_k) + \alpha(b, r_k) = -\alpha\|r_k\|^2 + \frac{1}{2}\alpha^2(Ar_k, r_k). \end{aligned}$$

vérifions qu'on retrouve bien la définition de la descente par gradient :

- si $\nabla g(u_k) = 0$, alors $u_{k+1} = u_k$

- sinon, on pose $d_k = \frac{-\nabla g(u_k)}{\|\nabla g(u_k)\|}$. On trouve bien que $d_k \in D_{u_k}$. On pose encore $t_k = \alpha\|\nabla g(u_k)\| > 0$. La propriété restant à vérifier pour la descente par gradient est que

$$\forall k \in \mathbb{N}, g(u_{k+1}) < g(u_k), \quad \text{c'est-à-dire } \alpha < \frac{2\|r_k\|^2}{(Ar_k, r_k)}$$

Or d'après les propriétés de A , ce quotient vérifie $\frac{2\|r_k\|^2}{(Ar_k, r_k)} \leq \frac{2\|r_k\|^2}{C\|r_k\|^2} = \frac{2}{C}$.

Ainsi, si on demande $0 < \alpha < \frac{2}{C}$, alors (u_k) est une suite de descente par gradient pour la fonction g .

Partie 4

15. On peut estimer la quantité étudiée $\rho_k = t_k(d_k, \nabla f(x_k))$ qui est négative. Elle vérifie $\rho_k \geq \frac{f(x_{k+1}) - f(x_k)}{m_1}$ puisque $m_1 > 0$.

Comme la suite $(f(x_k))$ est convergente, elle est bornée, et c'est également le cas des différences $f(x_{k+1}) - f(x_k)$. Ainsi (ρ_k) est minorée.

Mieux : si on forme la série $\sum_{k=0}^K \rho_k \geq \frac{f(x_{K+1}) - f(x_0)}{m_1}$: la somme partielle est également minorée. Or on sait que soit cette série à termes négatifs converge, soit la somme partielle tend vers $-\infty$. On peut donc affirmer que $\sum \rho_k$ converge et par suite que ρ_k tend vers 0.

Sous l'hypothèse (2), $\rho_k = t_k(d_k, \nabla f(x_k))$ a une limite nulle.

16. S'il existe un entier k tel que $(d_k, \nabla f(x_k)) = 0$ on a vu que cela signifiait que $\nabla f(x_k) = 0$ et $x_{k+1} = x_k$. Dans ce cas, la suite est constante à partir d'un certain rang, et $(d_k, \nabla f(x_k)) = 0$ à partir d'un certain rang.

Prenons maintenant le cas le plus général : pour tout k , $(d_k, \nabla f(x_k)) \neq 0$. On va manipuler des valeurs absolues pour que les termes soient positifs.

Si $t_k \geq C_1$, alors $|(d_k, \nabla f(x_k))| \leq \frac{1}{C_1} t_k |(d_k, \nabla f(x_k))|$.

Sinon, on sait que $t_k \geq C_2 |(d_k, \nabla f(x_k))|$ et ainsi $t_k |(d_k, \nabla f(x_k))| \geq C_2 |(d_k, \nabla f(x_k))|^2$.

Réunissons tout cela en une seule majoration :

$$|(d_k, \nabla f(x_k))| \leq \max \left(\frac{1}{C_1} t_k |(d_k, \nabla f(x_k))|, \sqrt{\frac{1}{C_2} t_k |(d_k, \nabla f(x_k))|} \right)$$

Le majorant a une limite nulle.

Sous les hypothèses (2) et (3), $(d_k, \nabla f(x_k))$ tend vers 0.

17. On étudie le terme $(BX|X)$ pour le vecteur $X = \nabla f(x_k) \neq 0$. Comme B est symétrique réelle, elle est diagonalisable en base orthonormale B . On note $\mu_1 \leq \dots \leq \mu_n$ les valeurs propres rangées par ordre croissant, et on sait que $\mu_1 > 0$.

En développant X dans la base $B = (e_1, \dots, e_n)$, il vient $X = \sum_{i=1}^n x_i e_i$, $BX = \sum_{i=1}^n x_i \mu_i e_i$ et comme la base est orthonormale

$$(BX, X) = \sum_{i=1}^n x_i^2 \mu_i \geq \sum_{i=1}^n x_i^2 \mu_1 = \|X\|^2 \mu_1$$

De même on trouve $\|BX\|^2 \leq \mu_n^2 \|X\|^2$.

Dès lors, $|(d_k, \nabla f(x_k))| = \frac{1}{\|BX\|} |(BX, X)| \geq \frac{\mu_1}{\mu_n} \|X\| = \frac{\mu_1}{\mu_n} \|\nabla f(x_k)\|$.

Sous ces hypothèses, $\nabla f(x_k)$ tend vers 0.

18. L'existence a déjà été prouvée ; montrons l'unicité par l'absurde, en supposant que \tilde{x} est un minimum global, distinct de x^* . On se place alors au milieu en posant $\lambda = \frac{1}{2}$:

$$f\left(\frac{1}{2}x^* + \frac{1}{2}\tilde{x}\right) < \frac{1}{2}f(x^*) + \frac{1}{2}f(\tilde{x}) = f(x^*).$$

On a trouvé un point pour lequel la valeur de f est strictement inférieure au minimum global ; c'est absurde. On n'a pas utilisé l'hypothèse \mathcal{C}^2 .

Dans le cas f strictement convexe et coercive, il y a unicité du minimum global.

On prouve, en vue de la question suivante, les propriétés issues de la stricte convexité : on compare d'abord des pentes

$$\text{si } z = \lambda x_1 + (1 - \lambda)x_2, \quad \lambda(f(z) - f(x_1)) < (1 - \lambda)(f(x_2) - f(z))$$

et encore

$$\lambda(z - x_1) \frac{f(z) - f(x_1)}{z - x_1} < (1 - \lambda)(x_2 - z) \frac{f(x_2) - f(z)}{x_2 - z}$$

Mais comme $\lambda(z - x_1) = (1 - \lambda)(x_2 - z) > 0$, il vient $\frac{f(z) - f(x_1)}{z - x_1} < \frac{f(x_2) - f(z)}{x_2 - z}$.

On a prouvé cela pour tout z de la forme $z = \lambda x_1 + (1 - \lambda)x_2$, c'est-à-dire tout point de $]x_1, x_2[$. L'implication sur les pentes est donc

$$x_1 < z < x_2 \Rightarrow \frac{f(x_1) - f(z)}{x_1 - z} < \frac{f(x_2) - f(z)}{x_2 - z}$$

Si on passe à la limite quand x_2 tend vers z , il vient $x_1 < z \Rightarrow \frac{f(x_1) - f(z)}{x_1 - z} \leq f'(z)$ et ensuite si x_1 tend vers z , $f'(x_1) \leq f'(z)$. C'est la croissance de f' .

Mais on a aussi établi $x_1 < z \Rightarrow f(x_1) \leq (x_1 - z)f'(z) + f(z)$, c'est-à-dire que le graphe est au-dessus de la tangente (d'un côté, mais l'autre se traite en faisant jouer un rôle symétrique à x_2).

Avec la (stricte) convexité donnée, il y a (stricte) croissance de f' et le graphe est au-dessus des tangentes.

19. On est dans le cas $n = 1$, avec ce qui a été dit au-dessus sur ce que deviennent les notations dans ce cadre. Commençons par le second point.

Par la question 16, on a $d_k f'(x_k)$ qui tend vers 0 avec $d_k = \pm 1$, donc $f'(x_k)$ qui tend vers 0. La suite (x_k) est bornée (question 13) donc elle admet au moins une sous-suite convergente (Bolzano-Weierstrass, admis ici). Soit une telle sous-suite $x_{\varphi(k)}$ et soit x_∞ sa limite. Alors $f(x_k)$ converge vers $f(x_\infty)$ par continuité et de même $f'(x_k)$ converge vers $f'(x_\infty)$. Ainsi $f'(x_\infty) = 0$. Par convexité, la fonction f est au-dessus de la tangente en x_∞ , donc de la droite horizontale $y = f(x_\infty)$. Ceci montre que x_∞ est l'unique minimum global de f .

Toute suite extraite de (x_k) qui converge converge vers x_* . Comme il est demandé de l'admettre, on peut énoncer que cela prouve que x_k converge vers x^* .

Avec les hypothèses de la question 18, ainsi que (2) et (3), la suite (x_k) converge vers x^* .

Voyons l'algorithme... ça ne paraît pas simple! Voici une proposition incomplète :

1. Je délimite un domaine borné contenant x_0 et x^* . Pour cela on peut exploiter la monotonie de f' : je cherche a et b tels que $f'(a) < 0, f'(b) > 0$. Quitte à l'agrandir, le segment $[a, b]$ contient x_0 .

2. J'appelle L un majorant de $|f''|$ sur $[a, b]$. J'ai donc une formule de Taylor :

$$f(x_{k+1}) = f(x_k) + t_k d_k f'(x_k) + R_k = f(x_k) - t_k |f'(x_k)| + R_k, \quad \text{où } |R_k| \leq \frac{1}{2} t_k^2 L$$

On souhaite avoir t_k vérifiant une condition du type $-t_k |f'(x_k)| + R_k \leq -m_1 t_k |f'(x_k)|$.

Il suffit pour cela d'avoir $m_1 t_k |f'(x_k)| + \frac{1}{2} t_k^2 L \leq t_k |f'(x_k)|$.

Je choisis donc $m_1 = \frac{1}{2}$ et j'impose $t_k = \frac{1}{L} |f'(x_k)|$. Cela me donne (2) (et notamment qu'il s'agit d'une descente par gradient), et (3).

3. Il y a un point qui n'est pas évident : est-ce que je reste dans $[a, b]$? Pour le garantir, il me semble que le plus accessible est d'utiliser la monotonie de f . Par exemple si on arrive à se débrouiller pour partir avec a, b tels que $f(a) = f(b)$, il est sûr que $f(x_k) \leq f(a)$ et donc que x_k reste dans $[a, b]$. Mais je ne sais pas si on attendait un questionnement aussi précis...